ĐẠI HỌC TÔN ĐỨC THẮNG
TON DUC THANG UNIVERSITY

BÁO CÁO GIỮA KỲ · INTRODUCTION TO MACHINE LEARNING

Hồi quy & Phân loại

Từ Gradient Descent tự cài đặt đến so sánh 14 bộ phân loại trên OpenML

Giảng viên hướng dẫn

Lê Anh Cường, Ph.D.

Sinh viên thực hiện

Ngô Lâm Tiến — 524H0195
Nguyễn Công Thành — 524H0191
Nguyễn Lê Nhật Tâm — 524H0186

Tháng 10 năm 2026

NỘI DUNG

Ba phần, ba người trình bày

01 **Câu 1 · Gradient Descent tự cài đặt** — Ngô Lâm Tiến

Hồi quy tuyến tính và logistic: mô hình, mất mát, dẫn xuất gradient, kết quả

02 **Câu 2 · Phân loại trên OpenML credit-g** — Nguyễn Công Thành

Tiền xử lý, quy trình chống rò rỉ dữ liệu, 14 mô hình và baseline

03 **Overfitting và cách khắc phục** — Nguyễn Lê Nhật Tâm

Bằng chứng thực nghiệm, các biện pháp, kết luận và hạn chế của bài làm

Câu hỏi xuyên suốt: mô hình học được gì từ dữ liệu, và làm sao biết nó thật sự tổng quát hóa?

Mô hình và hàm mất mát

Dự đoán

$$\hat{y}_i = w^T x_i + b$$

một đặc trưng → đường thẳng · nhiều đặc trưng → siêu phẳng

Mất mát: trung bình bình phương sai số

$$J(w, b) = (1/2n) \cdot \Sigma_i (\hat{y}_i - y_i)^2$$

- **Đầu ra là số thực** — bài toán hồi quy, không phải phân loại.
- **Hệ số ½** chỉ để đạo hàm gọn; nghiệm tối ưu không đổi.
- **Bình phương** khiến sai số lớn bị phạt nặng.
- **Chia cho n** để mất mát là trung bình, so sánh được giữa các cỡ mẫu.

Dữ liệu tổng hợp: 600 mẫu, 3 đặc trưng độc lập đều trên $[-3, 3]$; $y = 4 + 3x_1 - 2x_2 + 1.5x_3 + \varepsilon$, $\varepsilon \sim N(0, 0.5^2)$.

Dẫn xuất gradient và vòng lặp Gradient Descent

Đạo hàm riêng

đặt $e_i = \hat{y}_i - y_i \Rightarrow \partial e_i / \partial w_j = x_{ij}$

$\partial J/\partial w_j = (1/n)\ \Sigma_i\ e_i x_{ij}$ $\partial J/\partial b = (1/n)\ \Sigma_i\ e_i$

$\nabla_w J = (1/n)\ X^T(\hat{y} - y)$

Cập nhật đồng thời

$w^{(t+1)} = w^{(t)} - \eta \cdot (1/n)\ X^T e^{(t)}$

– Khởi tạo **w = 0, b = 0**; tốc độ học **η = 0.3**

– Dừng khi **chuẩn gradient ≤ 10^{-8}** — chỉ dùng dữ liệu huấn luyện

– Hội tụ sau **1175 vòng** trên 480 mẫu train

– Gradient được kiểm chứng bằng **sai phân trung tâm**, dung sai 10^{-6}

Cả hai gradient được tính trước khi cập nhật tham số (full-batch). Không bao giờ dùng chỉ số test để quyết định dừng.

Xác suất, cross-entropy và gradient

Mô hình xác suất

$$z = w^T x + b \Rightarrow p = \sigma(z) = 1 / (1 + e^{-z})$$

$$\log (p / (1 - p)) = w^T x + b \rightarrow \text{biên quyết định tuyến tính}$$

Mất mát: cross-entropy nhị phân

$$J = -(1/n) \Sigma_i [\, y_i \log p_i + (1 - y_i) \log (1 - p_i) \,]$$

$$\sigma'(z) = \sigma(z)(1 - \sigma(z))$$

$$\Rightarrow \partial \ell / \partial z = p - y$$

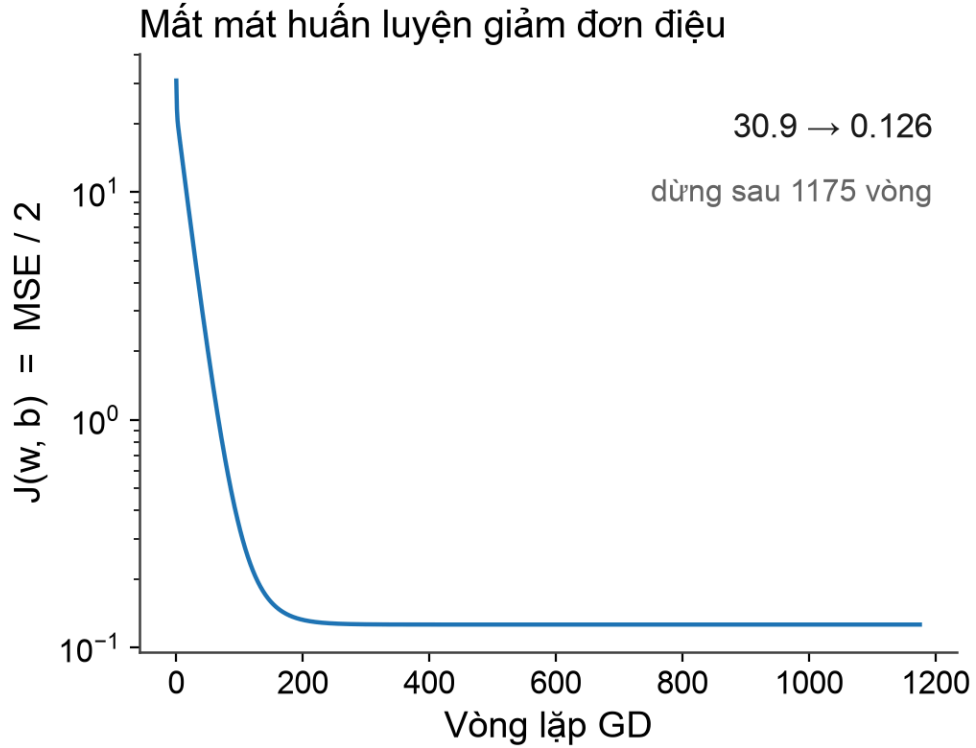
$$\nabla_w J = (1/n)\, X^T (p - y)$$

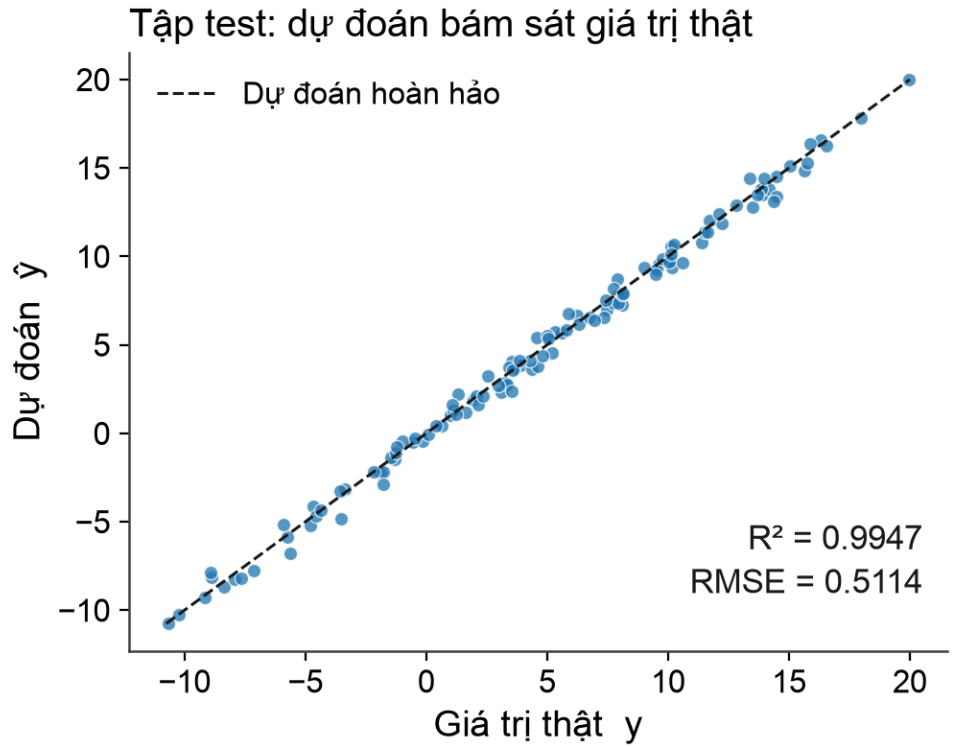
Cập nhật

$$w^{(t+1)} = w^{(t)} - \eta \cdot (1/n) X^T (p - y)$$

– **Mẫu số p(1 − p) triệt tiêu**, nên gradient giống hồi quy tuyến tính nhưng thay ŷ bằng p.
– **η = 0.5, tối đa 5000 vòng** — dừng theo ngân sách, chuẩn gradient cuối ≈ 1.55×10^{-4}.
– **Sigmoid và logaddexp** dạng ổn định số học; ngưỡng cố định 0.5, ROC-AUC dùng xác suất.

Hồi quy tuyến tính: học đúng quan hệ sinh dữ liệu



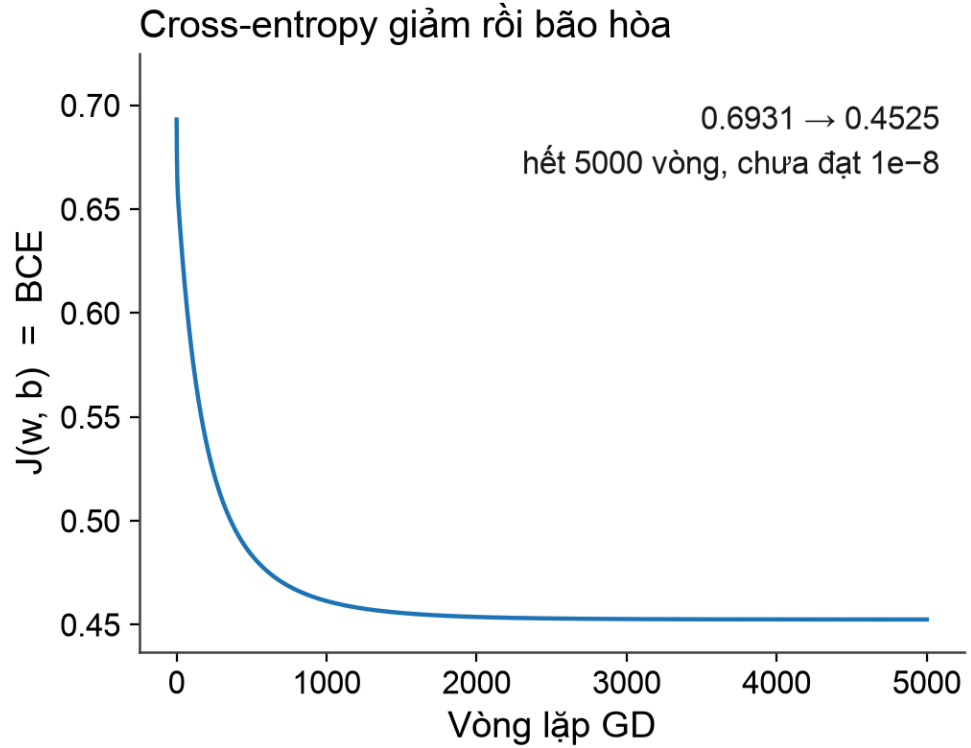


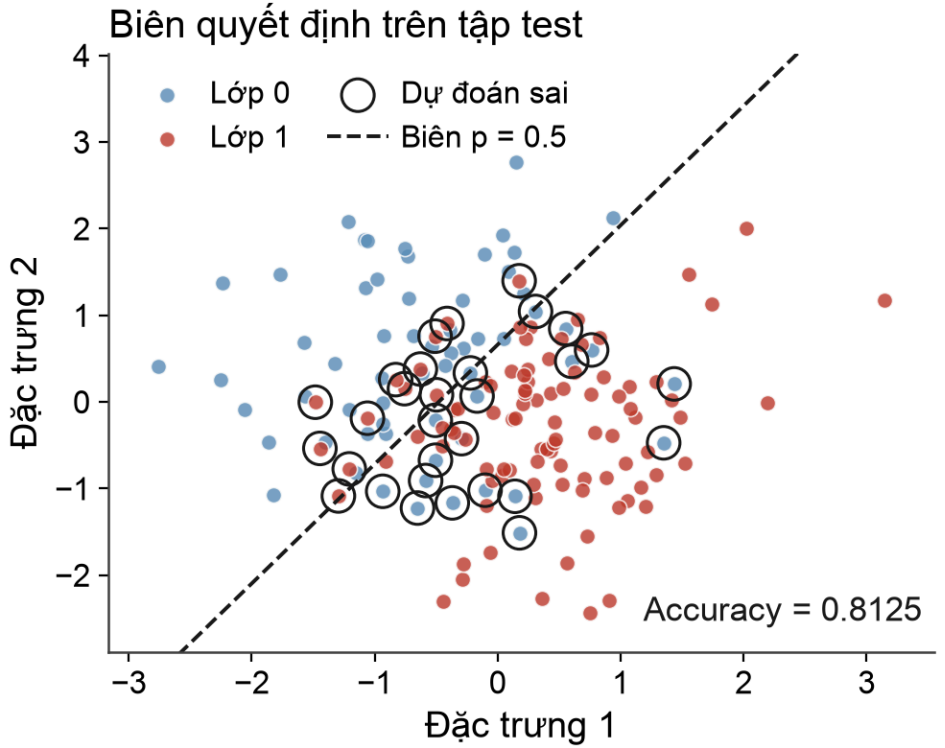
0.5114
RMSE trên tập test

0.9947
R^2 trên tập test

2.99 · −2.01 · 1.49
Trọng số học được (thật: 3 · −2 · 1.5)

Hồi quy logistic: biên hợp lý, nhưng còn 30 ca sai





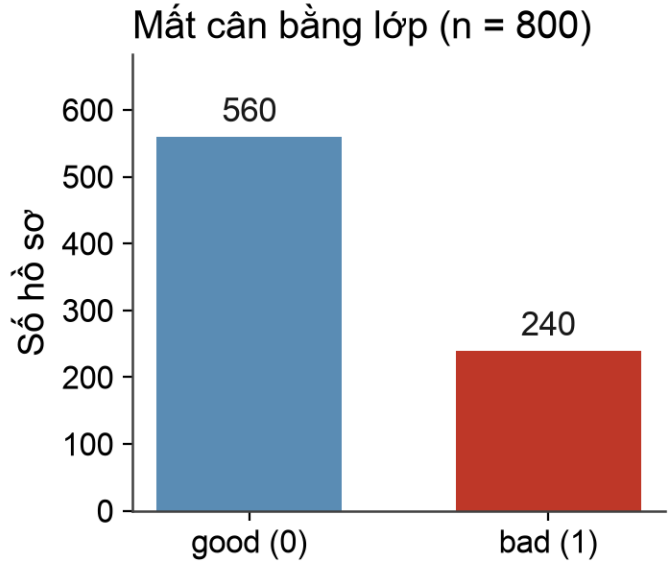
0.8125
Accuracy trên tập test

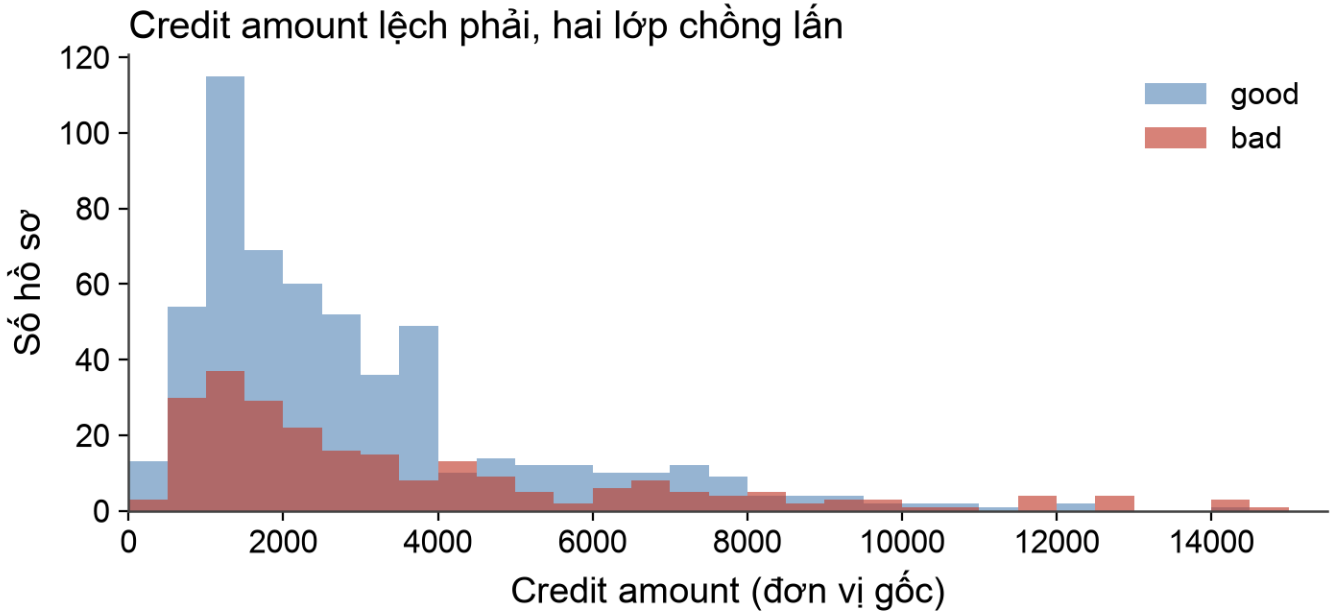
0.8515
F1 của lớp dương (p ≥ 0.5)

0.8576
ROC-AUC

44/18/12/86
Ma trận nhầm lẫn (TN/FP/FN/TP)

OpenML credit-g: 1000 hồ sơ, 20 biến, lệch lớp





ID 31 · v1
Nguồn gốc, MD5 đã kiểm tra

0 · 0 · 0
Ô thiếu · dòng trùng · giá trị lạ

800 / 200
Development / test, phân tầng, seed 42

61
Đặc trưng sau min–max và one-hot

Chống rò rỉ dữ liệu bằng thiết kế, không bằng lời hứa

01
Chia tập trước
800 development / 200 test, phân tầng, seed 42

→

02
Chuẩn hóa trong từng fold
min–max + one-hot, chỉ fit trên train của fold

→

03
5-fold stratified CV
cùng chỉ số fold cho mọi ứng viên, chọn theo macro F1

→

04
Test đúng một lần
refit trên 800 hồ sơ rồi mới dự đoán 200 hồ sơ

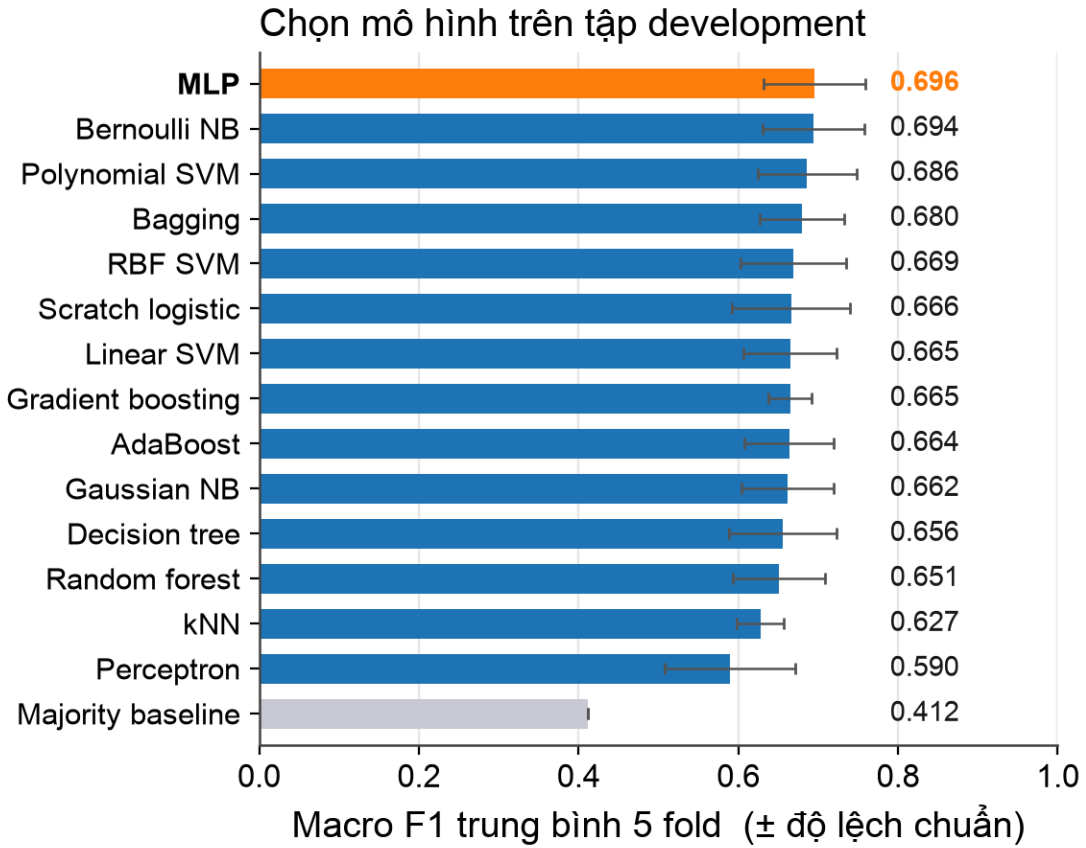
– **Toàn bộ lựa chọn hoàn tất trước khi sinh bất kỳ dự đoán test nào**.

– **Mọi mô hình dùng chung một phép biến đổi**, nên so sánh giữa chúng là công bằng.

– **Giữ nguyên ngoại lai hợp lệ** — cờ IQR chỉ là mô tả, không phải bằng chứng dữ liệu sai.

– **Baseline đa số** đạt macro F1 0.412 trên test, dùng làm mốc tham chiếu.

14 mô hình và một baseline, chọn bằng cross-validation



– **Ba kernel SVM** là ba biến thể của một họ, không phải ba họ độc lập.

– Dẫn đầu: MLP **0.696** · Bernoulli NB **0.694**

– Chênh lệch top 2 nhỏ hơn độ lệch chuẩn giữa các fold (±**0.06**) ⇒ chưa thể nói hơn kém.

– **kNN chọn k = 1** dù khoảng cách train–CV lớn: giữ đúng tiêu chí đã khai báo.

Điểm CV dùng để chọn tham số nên không phải đánh giá độc lập; tập test giữ vai trò đó.

Trên 200 hồ sơ chưa từng thấy, khoảng cách rất hẹp

Mô hình	Accuracy	Macro F1	AUC
Majority baseline	0.700	0.412	0.500
Perceptron	0.700	0.639	0.720
kNN (k = 1)	0.720	0.667	0.667
Decision tree	0.645	0.606	0.692
Scratch logistic	0.780	0.730	0.801
Polynomial SVM	0.775	0.713	0.799
AdaBoost	0.785	0.726	0.790
MLP (được chọn)	**0.790**	**0.730**	**0.813**

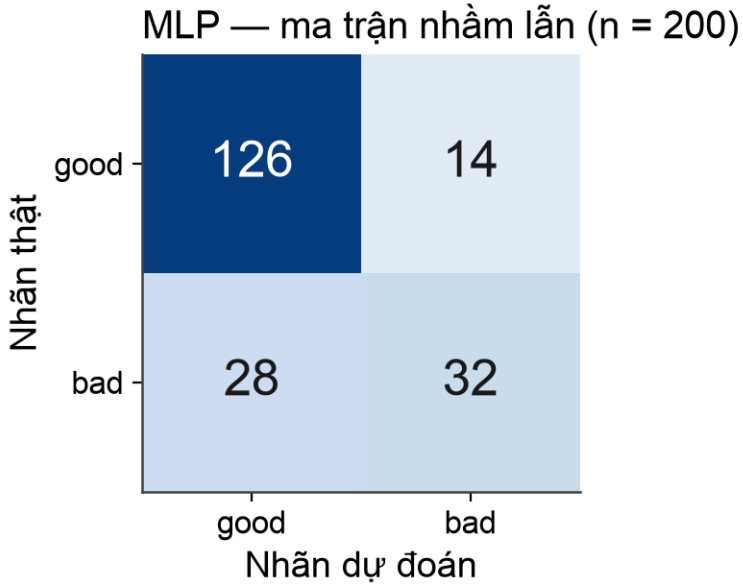
– MLP **0.7305** ≈ hồi quy logistic tự cài đặt **0.7301** — mô hình phức tạp không tạo khác biệt rõ.

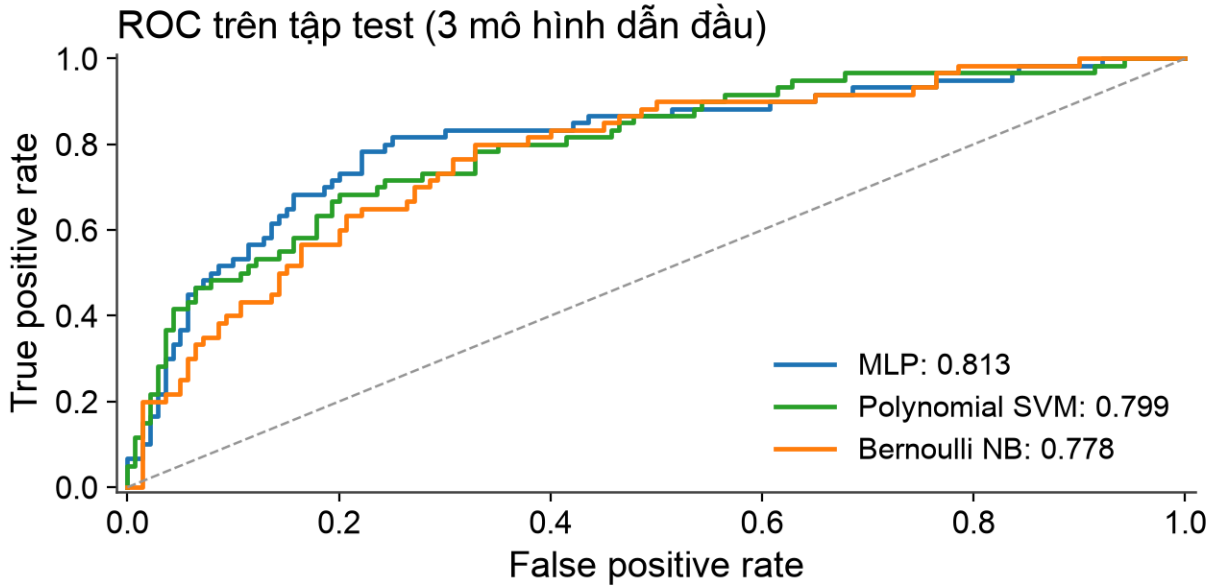
– Accuracy cao **0.79** nhưng phải đọc kèm chỉ số theo lớp, vì lớp bad chỉ chiếm 30%.

– **14 mô hình đều vượt baseline**, kể cả cây quyết định có accuracy thấp hơn.

Chênh lệch giữa các mô hình dẫn đầu chỉ vài phần nghìn — nhỏ hơn dao động giữa các fold (±0.064), nên không đọc thành xếp hạng.

Một con số accuracy đẹp có thể che mất lỗi quan trọng



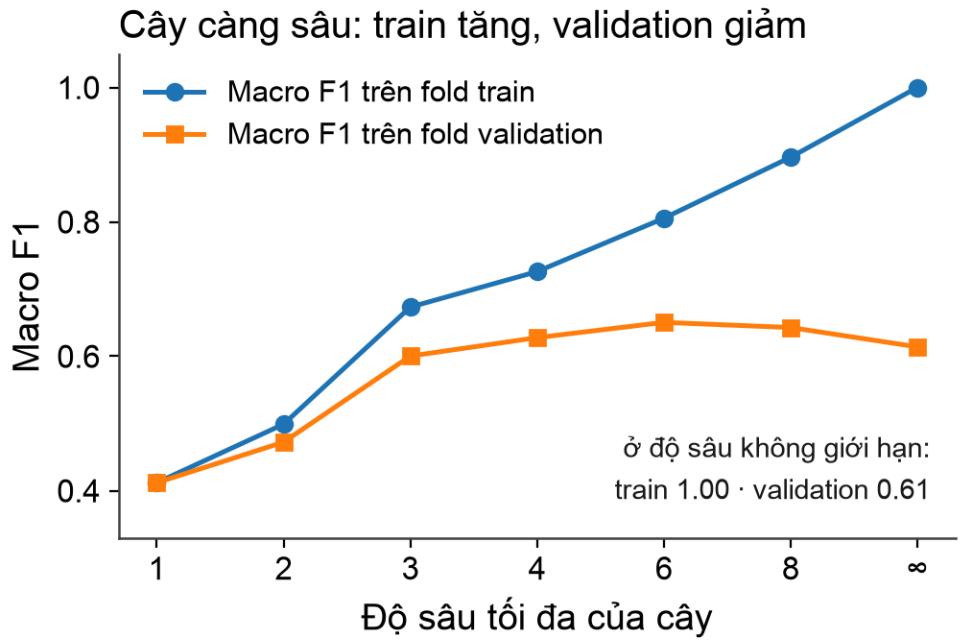


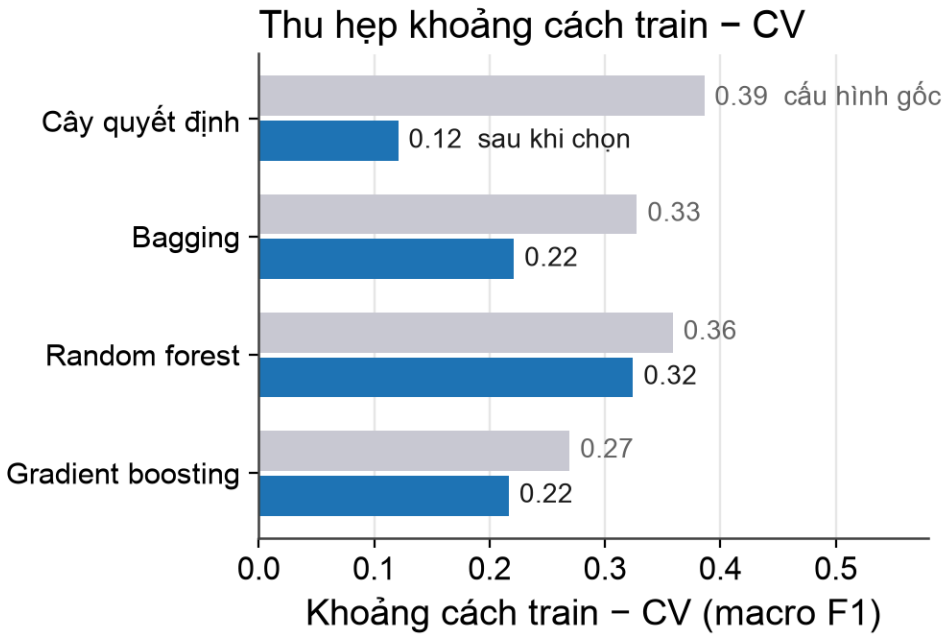
158/200 dự đoán đúng, nhưng **bỏ sót 28/60 hồ sơ "bad"** → recall lớp bad chỉ 0.533.

– Gaussian NB có recall bad cao nhất **0.650**, nhưng precision chỉ 0.513: bắt được nhiều hơn, báo nhầm cũng nhiều hơn.

– **Đánh đổi này là quyết định nghiệp vụ**, không phải lỗi kỹ thuật — và nhóm không hạ ngưỡng sau khi đã xem test.

Bằng chứng: cây càng sâu, khoảng cách càng lớn





0.386 → 0.121

Khoảng cách train − CV của cây quyết định sau khi giới hạn độ sâu 6 và tối thiểu 5 mẫu/lá.

1.00 / 0.614

Cây không giới hạn: hoàn hảo trên train nhưng validation thấp hơn cây bị giới hạn.

0.324

Random forest vẫn còn khoảng cách lớn — ensemble không tự chữa được overfitting.

Biện pháp chung: giới hạn độ phức tạp · chọn tham số bằng validation · giữ tập test riêng · báo cáo cả điểm train và validation.

Điều nhóm làm được, điều còn hạn chế

Kết quả chính

– Câu 1: hai mô hình tự cài đặt, gradient khớp sai phân trung tâm, RMSE xấp xỉ nhiễu sinh dữ liệu.

– Câu 2: 14 mô hình trên cùng bộ fold; MLP được chọn với macro F1 test 0.7305.

– Chi phí của accuracy: bỏ sót 28/60 hồ sơ xấu dù accuracy 0.79.

Bài học

– Tách test trước và chuẩn hóa trong fold là điều kiện của một so sánh đáng tin.

– Chênh lệch nhỏ hơn dao động giữa các fold thì chưa kết luận được hơn kém.

– Overfitting đo được bằng khoảng cách train − validation, và giảm được bằng giới hạn độ phức tạp.

Hạn chế

– Một bộ dữ liệu, một lần chia test, lưới tham số nhỏ.

– Hồi quy logistic chạm 5000 vòng, MLP chạm 500 epoch: chưa hội tụ.

– Không có kiểm định thống kê hay lặp lại với nhiều seed.

Cảm ơn thầy và các bạn đã lắng nghe — nhóm sẵn sàng nhận câu hỏi.